

# Note of numerical optimaization

PB19000252 王梓睿

2022 年 10 月 5 日

## 1 introduction

1、连续优化问题通常比离散优化问题容易，因为连续性带来在特定点附近，限制条件不会变化太大。

2、有时候约束优化问题可以表示成无约束优化问题，方法是将约束添加到目标函数的惩罚项当中，从而阻止违反约束。

3、凸优化的局部最优解就是全局最优解。

证明. 设  $x$  为局部最优解（最小值）， $y \neq x$  为全局最优解，连接  $y$  与  $x$ ，路径与  $x$  的任一邻域有交，从而由凸函数性质，与  $x$  的局部最优性矛盾.  $\square$

本书大部分情况下我们只关心局部最优。

4、随机最优化解出的是模型的期望表现。

5、凸优化的定义：

①是约束优化问题的一个特例；

①目标函数为凸函数；

②约束等式中右侧函数为线性函数；

③约束不等式中右侧函数为凹函数；

## 2 无约束最优化

### 2.1 关于解

- 1、孤立局部最小值一定严格局部最小，反之则不一定。
- 2、Taylor 公式（利用两种余项），由此可以推导几个结论。
  - ①  $f$  在局部最小值点  $x^*$  邻域内连续可微，则  $\nabla f(x^*) = 0$ ;
  - ②  $f$  在局部最小值点  $x^*$  邻域内，二阶导存在连续，则  $\nabla f(x^*) = 0$  且  $\nabla^2 f(x^*)$  半正定;
  - ③（充分性）在某点  $x^*$  邻域内二阶导存在连续，且  $f(x^*)=0, \nabla^2 f(x^*)$  正定，那么  $x^*$  为  $f$  的局部最小值点;
- 3、凸函数的局部最优值为全局最优值。若还可微，则任意稳定点都是全局最优值。

### 2.2 算法综述

- 1、线性探测法的最速下降方向是  $-\nabla f_k$ ，但收敛速度过慢。容易证明在与  $-\nabla f_k$  夹角小于  $\pi/2$  的方向上目标函数总会递减，称这些方向为下降方向。
- 2、牛顿方向为  $-(\nabla^2 f_k)^{-1} \nabla f_k$  适用于  $f_k$  的 Hessian 矩阵正定，且函数越光滑误差越小。它收敛速度较快，但 Hessian 矩阵计算量较大。
- 3、准牛顿方法用近似的  $B_k$  矩阵代替 Hessian，给出  $-(B_k)^{-1} \nabla f_k$  并在迭代中更新  $B_k$ ，从而减小计算量。
- 4、非线性共轭方法，采用公式  $p_k = -\nabla f_k + \beta_k p_{k-1}$ ，保留了最速下降法的计算简便性的同时提高了其收敛速度。
- 5、缩放，可以通过对角缩放等方式将变量大小拉到同一数量级。牛顿法能够比最速下降法更好地处理 poorly scaled 问题。

### 3 线性探测法

线性探测法先计算行进方向  $p_k$ ，再计算步长  $\alpha_k$ ，迭代公式为  $x_{k+1} = x_k + \alpha_k p_k$ 。行进方向的选取通常要求  $f_k$  递降，一般令  $p_k = -(B_k)^{-1} \nabla f_k$ ，如果  $B_k$  正定，由 Taylor 公式，一次项可化为  $-\nabla f_k^T B_k^{-1} \nabla f_k < 0$ ，这样  $f_k$  能够递降。

#### 3.1 步长

给定初值  $x_k$  和方向  $p_k$ ，我们记  $f_k(x_k + \alpha_k p_k)$  为单变量函数  $\phi(\alpha_k)$ ，想让其尽可能的小。我们引入概念“充分递降”。

##### 3.1.1 Wolfe 条件

1、Armijo 条件： $f(x_k + \alpha_k p_k) \leq f(x_k) + c_1 \alpha_k \nabla f_k^T p_k$ 。它保证了迭代过程至少线性收敛。

2、曲率条件： $\nabla f(x_k + \alpha_k p_k)^T p_k \geq c_2 \nabla f_k^T p_k$ 。事实上就是  $\phi'(\alpha_k) \geq c_2 \phi'(0)$ ，来保证下降的梯度在某一区间内。

3、 $0 < c_1 < c_2 < 1$  时，以上两式合称 Wolfe 条件。若 2 式改写为  $|LHS| \leq |RHS|$ ，则称为强 Wolfe 条件（进一步缩小了梯度的可能区间）。引理：任一连续可微有下界的函数，一定有满足（强）Wolfe 条件的区间。

##### 3.1.2 其它

1、Goldenstein 条件： $f(x_k) + (1 - c_1) \alpha_k \nabla f_k^T p_k \leq f(x_k + \alpha_k p_k) \leq f(x_k) + c_1 \alpha_k \nabla f_k^T p_k$ 。

2、回溯线性搜索：仅用 Armijo 条件进行判断，但每次不满足都执行  $\alpha = \rho \alpha$ ， $\rho$  为收缩因子。 $\rho$  可以在迭代过程中发生变化。

#### 3.2 收敛性

考虑  $\theta_k$  为方向  $p_k$  与最速下降方向  $-\nabla f_k$  的夹角。

1、Zoutendijk 条件：对满足一系列条件的  $f$  成立

$$\sum_0^{\infty} \cos^2 \theta_k \|\nabla f_k\|^2 < \infty$$

**Theorem 3.2.**

Consider any iteration of the form (3.1), where  $p_k$  is a descent direction and  $\alpha_k$  satisfies the Wolfe conditions (3.6). Suppose that  $f$  is bounded below in  $\mathbb{R}^n$  and that  $f$  is continuously differentiable in an open set  $\mathcal{N}$  containing the level set  $\mathcal{L} \stackrel{\text{def}}{=} \{x : f(x) \leq f(x_0)\}$ , where  $x_0$  is the starting point of the iteration. Assume also that the gradient  $\nabla f$  is Lipschitz continuous on  $\mathcal{N}$ , that is, there exists a constant  $L > 0$  such that

$$\|\nabla f(x) - \nabla f(\tilde{x})\| \leq L\|x - \tilde{x}\|, \quad \text{for all } x, \tilde{x} \in \mathcal{N}. \quad (3.13)$$

Then

$$\sum_{k \geq 0} \cos^2 \theta_k \|\nabla f_k\|^2 < \infty. \quad (3.14)$$

2、如果上述级数收敛，说明  $\cos^2 \theta_k \|\nabla f_k\|^2 \rightarrow 0$ 。当  $\theta_k$  有界地远离 90 度时，即存在  $\delta, \cos \theta_k \geq \delta > 0$ ，那么有  $\|\nabla f_k\| \rightarrow 0$ ，我们称为全局收敛。

3、类牛顿方法中，如果矩阵  $B_k$  的条件数  $\|B_k\| \|B_k^{-1}\| \leq M$ ， $M$  为一个常数，则可以证明全局收敛性。

### 3.3 收敛率

1、我们可以定义  $Q$  范数，并证明  $f(x) = \frac{1}{2}x^T Qx - b^T x$  时，有  $\frac{1}{2}\|x - x^*\|_Q^2 = f(x) - f(x^*)$ 。

2、thm3.3，可以证明对严格凸的二次函数  $f$ ，有

$$\|x_{k+1} - x^*\|_Q^2 \leq \left(\frac{\lambda_n - \lambda_1}{\lambda_n + \lambda_1}\right)^2 \|x_k - x^*\|_Q^2.$$

其中  $0 < \lambda_1 \leq \dots \leq \lambda_n$  为  $Q$  的特征值。这意味着  $f_k$  至少以线性收敛到  $f^*$ 。

3、thm3.5, 如果  $f$  二次可微, Hessian 在解  $x^*$  附近李普希兹连续, 那么  $x$

(i) 若起始点  $x_0$  离  $x^*$  足够近, 那么迭代序列收敛到  $x^*$ 。

(ii)  $x_k$  有二阶收敛速度,  $\|\nabla f_k\|$  二阶收敛到 0。

4、thm3.6, 此定理说明了在  $p_k$  满足一个极限式的时候,  $k$  较大时可直接将  $\alpha_k$  取 1, 且此时  $x_k$  超线性收敛到  $x^*$ 。thm3.7 说明了  $\alpha_k$  恒取为 1 的情况下, 3.6 的条件是充要的。而准牛顿方法满足这一条件, 因此能够超线性收敛。

### 3.4 Hessian 修正

我们希望能够找到方阵  $E_k$ , 使得  $B_k = \nabla^2 f(x_k) + E_k$  正定。要求这一修改尽量小, 以保留 Hessian 矩阵的更多信息。1、可以考虑  $\nabla^2 f_k + \tau I$ , 并在迭代中不断增加  $\tau_k$  的值。但是这样每次更新  $\tau$  后都要重新对矩阵进行分解, 计算量太大。

2、Cholesky 分解, 可以在算法中引入两个新的变量列, 从而边分解边进行矩阵修改。(注意并不是先分解为  $L^T D L$  再修改  $D$ , 因为首先我们无法保证分解的存在性, 其次修改后的结果不稳定)

3、更稳定的方法是进行对称不定分解  $A = L^T B L$ , 其中  $A$  须为对称矩阵,  $B$  为准对角阵, 对角块大小为 1 或 2. 这一分解必定存在。

### 3.5 步长选择算法

#### 3.5.1 插值算法

1、从  $\phi(0), \phi'(0)$ , 及初始步长  $\alpha_0$  构造出  $\alpha_1$ , 随后构造出三次插值函数, 利用  $\phi(0), \phi'(0), \alpha_{k-1}, \alpha_k$  来计算  $\alpha_{k+1}$ 。这一方法并没有计算在诸  $\alpha_i$  处的导数值。

2、如果导数值比较好算, 我们可以用  $\phi(\alpha_{i-1}), \phi(\alpha_i), \phi'(\alpha_{i-1}), \phi'(\alpha_i)$  来对  $\alpha_{i+1}$  作三次插值。

### 3.5.2 Wolfe 条件下的线性搜索算法

先利用两个不等式确定一个目标值存在的区间，再调用 Zoom 函数不断缩小区间的范围，以得到满足 Wolfe 条件的值。

## 4 置信区域法

基本思想是先在迭代中更新置信区域及其半径，再在该区域内寻找步长和方向。

我们定义  $m_k(p) = f_k + g_k^T p + \frac{1}{2} p^T B_k p$ ,  $B_k$  只限定对称和一致有界，来考虑  $\|p\| \leq \Delta_k$  时的  $m_k$  最小值。

### 4.1 Overview

1、Algo4.1 描述了置信区域法的一般算法。记  $\rho_k = \frac{f(x_k) - f(x_k + p_k)}{m_k(0) - m_k(p_k)}$ ，如果  $\rho_k$  为负，说明  $f$  增加，必须拒绝。若  $\rho_k$  接近 1，说明预测模型很好，可以扩大置信半径；反之若  $\rho_k$  接近 0 说明模型不好，需要缩小置信半径。

2、thm 4.1 刻画了求  $m_k(p)$  取最小值的条件，即  $\exists \lambda \geq 0, s.t.$

$$(B + \lambda I)p^* = -g,$$

$$\lambda(\Delta - \|p^*\|) = 0,$$

$$(B + \lambda I) \text{ 正定.}$$

### 4.2 柯西点

1、设  $p_k^s = \operatorname{argmin} f_k + g_k^T p, \|p\| \leq \Delta_k$ ，再计算  $\tau_k$  使得  $m_k(\tau p_k^s)$  最小且  $\|\tau p_k^s\| \leq \Delta_k$ ，我们把求得的  $p_k^c = \tau_k p_k^s$  称为柯西点。柯西点计算比较容易，但由于不太依赖矩阵  $B_k$  的值，也注定了收敛速度不会太快。

（接下来考察单步迭代内部的求解过程，暂时忽略下标  $k$ ）

2、Dogleg Method (折线法), 当仅  $B$  正定时可以使用。思想是用两条线段组成的折线代替解曲线, 分别是起始点到  $p^U // g$ , 和  $p^B // -B^{-1}g$ 。thm4.2 证明了这一折线段  $\tilde{p}(\tau)$  上  $\|\tilde{p}(\tau)\|$  单增, 且  $m(\tilde{p}(\tau))$  单减。

3、二维子空间法, 是 dogleg 的推广, 代替了  $p^U, p^B$  两个方向, 而在  $\text{span}[p^U, p^B]$  中找。这一方法可以进一步改为在  $\text{span}[g, (B + \alpha I)^{-1}g]$  中找, 从而不再需要  $B$  的正定性。

### 4.3 全局收敛

1、lemma4.3 给出了  $m_k$  下降的一个估计, 式子形式类似 Wolfe 第一个条件。

2、thm4.4 说明了只要近似解  $p_k$  能够满足使  $m_k$  下降柯西点处减少值的一个固定倍数即可满足 lemma4.3。

3、thm4.5, thm4.6 给出了 Algo4.1 中  $\eta$  分别取 0 和大于 0 的某一正数时, 梯度序列  $g_k$  的下极限和极限为 0。

### 4.4 子问题的迭代解

1、先介绍了如何处理  $\|p(\lambda)\| = \Delta$  问题的解。利用奇异值分解可以写出

$$\|p(\lambda)\|^2 = \sum_{j=1}^n \frac{(q_j^T g)^2}{(\lambda_i + \lambda)^2}$$

。作出图像 ( $P_{104}$ ), 可以看出, 当  $q_1^T g \neq 0$  时, 函数在  $-\lambda_1$  处取  $\infty$ , 在无穷远处取 0, 从而必存在目标解。随后可以利用 Newton 迭代法进行求解 (可以通过取倒数等定义新函数使迭代过程更加稳定)。而当  $q_1^T g = 0$  时, 定义新的函数  $p$ 。

2、Lemma4.7 给出了  $m(p) = g^T p + \frac{1}{2} p^T B p$  能取到最小值的充要条件和解满足的性质。并以此证明了 thm4.1。

## 4.5 Newton 法的局部收敛

thm4.9 证明了, 在一定的条件下, 置信区域  $\Delta_k$  会逐渐减小, 序列  $\{x_k\}$  会超线性收敛到一点。

## 4.6 其它改进方法

1、第二章提过, 优化问题的 Scaling 可能会很糟糕, 即在某些方向, 目标函数变化得过于剧烈。因此我们考虑椭圆置信区间, 可以描述为  $\|Dp\| \leq \Delta$ , 其中  $D$  是一个对角矩阵, 在对变化比较敏感的方向取较大的对角元。

然后提出了 Scaling 过的柯西点计算算法。

2、使用其它范数, 比如  $\|\cdot\|_\infty$ , 这在一些约束问题和一些数据比较大的问题中可以应用。

# 5 共轭梯度法

共轭梯度法可以用于解决线性的和非线性的问题。

## 5.1 线性共轭梯度法

记残差  $r_k = Ax_k - b$ 。我们称一组向量  $\{p_0, p_1, \dots, p_l\}$  为关于  $A$  共轭的, 当  $p_i^T A p_j = 0, \forall i \neq j$ , 其中  $A$  正定对称。

### 5.1.1 共轭方向法

1、thm5.1, 可以证明迭代  $x_{k+1} = x_k + \alpha_k p_k$  可以由任意起始点  $x_0 \in \mathbb{R}^n$  迭代至多  $n$  步找到解, 其中  $\alpha_k = -\frac{r_k^T p_k}{p_k^T A p_k}$ 。

2、thm5.2, 说明了  $r_k^T p_i = 0, \forall i < k$ , 即当前残差总正交于已搜索的全部方向。

3、Algo 5.2: 共轭梯度算法。



## 5.2 收敛率

本节大多数定理都在数值代数中学过，略去这些定理。

### 5.2.1 预处理

因为收敛速度被矩阵  $A$  的条件数控制，而条件数取决于  $A$  的特征值分布，我们可以用某个非奇异矩阵  $C$  对向量  $x$  进行变换。Algo5.3 给出了增加预处理的共轭梯度算法。

随后介绍了一些选择预处理条件矩阵  $M$  的方法，如不完全 Cholesky 分解。

## 5.3 非线性共轭梯度法

### 5.3.1 Fletcher-Reeves 方法

1、Algo 5.4, 对 Algo 5.2 的简单改造。接下来探讨了强 Wolfe 条件对  $p_k$  的限制, 以及  $\beta_k$  的其它选取方法, 如 Polak-Ribiere, FR-PR, Hestnens-Stiefel 等。

2、重启。我们可以每  $n$  步就重置一次迭代, 并且可以证明这一重启的过程具有二次收敛性。然而由于非线性问题的规模  $n$  往往很大, 我们实际上采用另一些策略, 比如考察两个相邻的梯度是否足够偏离正交, 这样重启的间隔更短。

3、Lemma 5.6, 证明了满足强 Wolfe 条件 (的第二式) 的  $\alpha_k$  能够保证下降方向满足一个不等式, 该不等式蕴含着  $\nabla f_k^T p_K < 0$ , 即方向确为函数递降方向。同时, 该不等式还能推断出 FR 方法的一个缺点, 就是当  $p_k$  与  $-\nabla f_k$  接近正交时 (即  $\cos \theta_k$  很小时), 会出现长时间的  $p_{k+1} \approx p_k$  的现象。因此 FR 方法通常必须和重启策略绑定使用。

### 5.3.2 全局收敛

1、对配备了重启的算法,可以由强 Wolfe 条件推出  $\sum_{k=0}^{\infty} \cos^2 \theta_k \|\nabla f_k\|^2 < \infty$  (Zoutendijk 条件)。这可以推出存在  $k$  的子列使  $\sum_{k_i} \|\nabla f_{k_i}\|^2 < \infty$ , 进而梯度的下确界是 0.

2、thm5.7 说明了 FR 方法中, 梯度的下确界也是 0。

3、thm5.8 说明了对一般性非凸的函数, PR 方法可能永远达不到解 (梯度的下确界不为 0)。

最后作者建议使用基于 PR, PR+ 或 FR-PR 的方法。