

# Note of numerical optimaization

PB19000252 王梓睿

2022 年 9 月 4 日

## 1 introduction

1、连续优化问题通常比离散优化问题容易，因为连续性带来在特定点附近，限制条件不会变化太大。

2、有时候约束优化问题可以表示成无约束优化问题，方法是将约束添加到目标函数的惩罚项当中，从而阻止违反约束。

3、凸优化的局部最优解就是全局最优解。

证明. 设  $x$  为局部最优解（最小值）， $y \neq x$  为全局最优解，连接  $y$  与  $x$ ，路径与  $x$  的任一邻域有交，从而由凸函数性质，与  $x$  的局部最优性矛盾.  $\square$

本书大部分情况下我们只关心局部最优。

4、随机最优化解出的是模型的期望表现。

5、凸优化的定义：

①是约束优化问题的一个特例；

①目标函数为凸函数；

②约束等式中右侧函数为线性函数；

③约束不等式中右侧函数为凹函数；

## 2 无约束最优化

### 2.1 关于解

- 1、孤立局部最小值一定严格局部最小，反之则不一定。
- 2、Taylor 公式（利用两种余项），由此可以推导几个结论。
  - ①  $f$  在局部最小值点  $x^*$  邻域内连续可微，则  $\nabla f(x^*) = 0$ ;
  - ②  $f$  在局部最小值点  $x^*$  邻域内，二阶导存在连续，则  $\nabla f(x^*) = 0$  且  $\nabla^2 f(x^*)$  半正定;
  - ③（充分性）在某点  $x^*$  邻域内二阶导存在连续，且  $f(x^*)=0, \nabla^2 f(x^*)$  正定，那么  $x^*$  为  $f$  的局部最小值点;
- 3、凸函数的局部最优值为全局最优值。若还可微，则任意稳定点都是全局最优值。

### 2.2 算法综述

- 1、线性探测法的最速下降方向是  $-\nabla f_k$ ，但收敛速度过慢。容易证明在与  $-\nabla f_k$  夹角小于  $\pi/2$  的方向上目标函数总会递减，称这些方向为下降方向。
- 2、牛顿方向为  $-(\nabla^2 f_k)^{-1} \nabla f_k$  适用于  $f_k$  的 Hessian 矩阵正定，且函数越光滑误差越小。它收敛速度较快，但 Hessian 矩阵计算量较大。
- 3、准牛顿方法用近似的  $B_k$  矩阵代替 Hessian，给出  $-(B_k)^{-1} \nabla f_k$  并在迭代中更新  $B_k$ ，从而减小计算量。
- 4、非线性共轭方法，采用公式  $p_k = -\nabla f_k + \beta_k p_{k-1}$ ，保留了最速下降法的计算简便性的同时提高了其收敛速度。
- 5、缩放，可以通过对角缩放等方式将变量大小拉到同一数量级。牛顿法能够比最速下降法更好地处理 poorly scaled 问题。

### 3 线性探测法

线性探测法先计算行进方向  $p_k$ ，再计算步长  $\alpha_k$ ，迭代公式为  $x_{k+1} = x_k + \alpha_k p_k$ 。行进方向的选取通常要求  $f_k$  递降，一般令  $p_k = -(B_k)^{-1} \nabla f_k$ ，如果  $B_k$  正定，由 Taylor 公式，一次项可化为  $-\nabla f_k^T B_k^{-1} \nabla f_k < 0$ ，这样  $f_k$  能够递降。

#### 3.1 步长

给定初值  $x_k$  和方向  $p_k$ ，我们记  $f_k(x_k + \alpha_k p_k)$  为单变量函数  $\phi(\alpha_k)$ ，想让其尽可能的小。我们引入概念“充分递降”。

##### 3.1.1 Wolfe 条件

1、Armijo 条件： $f(x_k + \alpha_k p_k) \leq f(x_k) + c_1 \alpha_k \nabla f_k^T p_k$ 。它保证了迭代过程至少线性收敛。

2、曲率条件： $\nabla f(x_k + \alpha_k p_k)^T p_k \geq c_2 \nabla f_k^T p_k$ 。事实上就是  $\phi'(\alpha_k) \geq c_2 \phi'(0)$ ，来保证下降的梯度在某一区间内。

3、 $0 < c_1 < c_2 < 1$  时，以上两式合称 Wolfe 条件。若 2 式改写为  $|LHS| \leq |RHS|$ ，则称为强 Wolfe 条件（进一步缩小了梯度的可能区间）。引理：任一连续可微有下界的函数，一定有满足（强）Wolfe 条件的区间。

##### 3.1.2 其它

1、Goldenstein 条件： $f(x_k) + (1 - c_1) \alpha_k \nabla f_k^T p_k \leq f(x_k + \alpha_k p_k) \leq f(x_k) + c_1 \alpha_k \nabla f_k^T p_k$ 。

2、回溯线性搜索：仅用 Armijo 条件进行判断，但每次不满足都执行  $\alpha = \rho \alpha$ ， $\rho$  为收缩因子。 $\rho$  可以在迭代过程中发生变化。

#### 3.2 收敛性

考虑  $\theta_k$  为方向  $p_k$  与最速下降方向  $-\nabla f_k$  的夹角。

1、Zoutendijk 条件：对满足一系列条件的  $f$  成立

$$\sum_0^{\infty} \cos^2 \theta_k \|\nabla f_k\|^2 < \infty$$

**Theorem 3.2.**

Consider any iteration of the form (3.1), where  $p_k$  is a descent direction and  $\alpha_k$  satisfies the Wolfe conditions (3.6). Suppose that  $f$  is bounded below in  $\mathbb{R}^n$  and that  $f$  is continuously differentiable in an open set  $\mathcal{N}$  containing the level set  $\mathcal{L} \stackrel{\text{def}}{=} \{x : f(x) \leq f(x_0)\}$ , where  $x_0$  is the starting point of the iteration. Assume also that the gradient  $\nabla f$  is Lipschitz continuous on  $\mathcal{N}$ , that is, there exists a constant  $L > 0$  such that

$$\|\nabla f(x) - \nabla f(\tilde{x})\| \leq L\|x - \tilde{x}\|, \quad \text{for all } x, \tilde{x} \in \mathcal{N}. \quad (3.13)$$

Then

$$\sum_{k \geq 0} \cos^2 \theta_k \|\nabla f_k\|^2 < \infty. \quad (3.14)$$

2、如果上述级数收敛，说明  $\cos^2 \theta_k \|\nabla f_k\|^2 \rightarrow 0$ 。当  $\theta_k$  有界地远离 90 度时，即存在  $\delta, \cos \theta_k \geq \delta > 0$ ，那么有  $\|\nabla f_k\| \rightarrow 0$ ，我们称为全局收敛。

3、类牛顿方法中，如果矩阵  $B_k$  的条件数  $\|B_k\| \|B_k^{-1}\| \leq M$ ， $M$  为一个常数，则可以证明全局收敛性。

### 3.3 收敛率

1、我们可以定义  $Q$  范数，并证明  $f(x) = \frac{1}{2}x^T Qx - b^T x$  时，有  $\frac{1}{2}\|x - x^*\|_Q^2 = f(x) - f(x^*)$ 。

2、thm3.3，可以证明对严格凸的二次函数  $f$ ，有

$$\|x_{k+1} - x^*\|_Q^2 \leq \left(\frac{\lambda_n - \lambda_1}{\lambda_n + \lambda_1}\right)^2 \|x_k - x^*\|_Q^2.$$

其中  $0 < \lambda_1 \leq \dots \leq \lambda_n$  为  $Q$  的特征值。这意味着  $f_k$  至少以线性收敛到  $f^*$ 。

3、thm3.5, 如果  $f$  二次可微, Hessian 在解  $x^*$  附近李普希兹连续, 那么  $x$

(i) 若起始点  $x_0$  离  $x^*$  足够近, 那么迭代序列收敛到  $x^*$ 。

(ii)  $x_k$  有二阶收敛速度,  $\|\nabla f_k\|$  二阶收敛到 0。

4、thm3.6, 此定理说明了在  $p_k$  满足一个极限式的时候,  $k$  较大时可直接将  $\alpha_k$  取 1, 且此时  $x_k$  超线性收敛到  $x^*$ 。thm3.7 说明了  $\alpha_k$  恒取为 1 的情况下, 3.6 的条件是充要的。而准牛顿方法满足这一条件, 因此能够超线性收敛。

### 3.4 Hessian 修正

我们希望能够找到方阵  $E_k$ , 使得  $B_k = \nabla^2 f(x_k)$  正定。要求这一修改尽量小, 以保留 Hessian 矩阵的更多信息。1、可以考虑  $\nabla^2 f_k + \tau I$ , 并在迭代中不断增加  $\tau_k$  的值。但是这样每次更新  $\tau$  后都要重新对矩阵进行分解, 计算量太大。

2、Cholesky 分解, 可以在算法中引入两个新的变量列, 从而边分解边进行矩阵修改。(注意并不是先分解为  $L^T D L$  再修改  $D$ , 因为首先我们无法保证分解的存在性, 其次修改后的结果不稳定)

3、更稳定的方法是进行对称不定分解  $A = L^T B L$ , 其中  $A$  须为对称矩阵,  $B$  为准对角阵, 对角块大小为 1 或 2. 这一分解必定存在。

### 3.5 步长选择算法

#### 3.5.1 插值算法

1、从  $\phi(0), \phi'(0)$ , 及初始步长  $\alpha_0$  构造出  $\alpha_1$ , 随后构造出三次插值函数, 利用  $\phi(0), \phi'(0), \alpha_{k-1}, \alpha_k$  来计算  $\alpha_{k+1}$ 。这一方法并没有计算在诸  $\alpha_i$  处的导数值。

2、如果导数值比较好算, 我们可以用  $\phi(\alpha_{i-1}), \phi(\alpha_i), \phi'(\alpha_{i-1}), \phi'(\alpha_i)$  来对  $\alpha_{i+1}$  作三次插值。

### 3.5.2 Wolfe 条件下的线性搜索算法

先利用两个不等式确定一个目标值存在的区间，再调用 Zoom 函数不断缩小区间的范围，以得到满足 Wolfe 条件的值。